

Relatório T3

MC906: Redes Neurais do Zero com Interpretabilidade

Adriano Ribeiro Franulovic Campos, Andrei Quaresma Pinto, Matheus Ferracciú Scatolin,
Pietro Fernandes Magaldi, Tiago Perrupato Antunes

Maio/2026

Resumo

Implementamos uma rede neural multicamadas (MLP) *100% NumPy* para classificar tumores do dataset *Breast Cancer Wisconsin (Diagnostic)* em benignos ou malignos. O trabalho cobre forward pass, backpropagation e mini-batch SGD com ReLU, Softmax e cross-entropy; exploração de hiperparâmetros; avaliação final com early stopping; e interpretabilidade por gradientes de entrada e ablação. O melhor modelo alcançou **97,4%** de acurácia no conjunto de teste (115 amostras), com três erros.

1 Introdução

O diagnóstico precoce de câncer de mama depende de características morfológicas dos núcleos celulares extraídas de imagens histopatológicas. O dataset *Breast Cancer Wisconsin (Diagnostic)* [1] disponibiliza 569 amostras com 30 atributos numéricos por tumor (médias, piores valores e erros de medidas como raio, textura, concavidade etc.) e rótulo binário.

Objetivo do TP: construir do zero uma MLP capaz de classificar tumores, compreender o aprendizado via retropropagação e *explicar* as decisões do modelo. Não utilizamos PyTorch, TensorFlow ou bibliotecas equivalentes para o treinamento; apenas NumPy para a rede e scikit-learn para carregamento de dados, métricas auxiliares e comparação opcional.

Pré-processamento. Invertemos o encoding do scikit-learn para adotar B=0 (benigno) e M=1 (maligno). Aplicamos *split* estratificado 64/16/20% (363 treino, 91 validação, 115 teste), preservando a proporção de classes ($\approx 62,7\%$ benignos). Cada feature recebe z-score com média e desvio *calculados apenas no treino*, evitando vazamento de informação. Para treino usamos *one-hot encoding* dos rótulos, compatível com Softmax + cross-entropy.

A Figura 1 mostra projeção PCA 2D do teste: as classes são parcialmente separáveis, com região de sobreposição onde erros são mais prováveis.




Figura 1: Projeção PCA 2D do conjunto de teste (esquerda: rótulos reais; direita: $P(\text{maligno})$ do modelo *baseline*).

2 Implementação

2.1 Arquitetura

A rede é totalmente conectada com L camadas definidas por uma lista de tamanhos, e.g. $[30, 16, 2]$: 30 entradas, 16 neurônios ReLU na camada oculta e 2 logits de saída. Para cada camada l :

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \quad \mathbf{a}^{(l)} = \text{ReLU}(\mathbf{z}^{(l)}) \quad (l < L), \quad (1)$$

com $\mathbf{a}^{(0)} = \mathbf{x}$. Na saída aplicamos Softmax explícita:

$$p_i = \frac{e^{z_i}}{\sum_j e^{z_j}}. \quad (2)$$

2.2 Função de custo e retropropagação

Usamos cross-entropy multiclasse com rótulos *one-hot* $\mathbf{y}$:

$$\mathcal{L} = -\frac{1}{B} \sum_{b=1}^B \sum_i y_{bi} \log p_{bi}. \quad (3)$$

Combinando Softmax + CE, o gradiente na saída simplifica-se a $(\mathbf{p} - \mathbf{y})/B$, propagado pelas camadas ocultas via regra da cadeia e gradiente da ReLU: $\partial a / \partial z = \mathbb{I}[z > 0]$.

2.3 Otimização

Parâmetros atualizados por mini-batch SGD; opcionalmente com **momentum** μ : $\mathbf{v} \leftarrow \mu \mathbf{v} - \alpha \nabla \mathcal{L}$, $\theta \leftarrow \theta + \mathbf{v}$. Implementamos também inicialização **He** para camadas ReLU ($\mathcal{N}(0, \sqrt{2/n_{\text{in}}})$). Pesos padrão usam $\mathcal{N}(0, 0.01)$ e vieses zero. Validamos a implementação com *gradient check* numérico (erro $< 10^{-6}$).

3 Experimentos

3.1 Metodologia

Métricas: acurácia e loss de cross-entropy. Hiperparâmetros são selecionados pela **acurácia de validação** (média de 5 *seeds*); o teste é usado **uma única vez** após a escolha final (Seção 5). Em empates de validação, mantemos a configuração mais simples.

Baseline (Seção 3): $\text{arch}=[30,32,2]$, $\alpha = 0,1$, $\text{batch}=32$, 150 épocas, 3 *seeds*. Converge rapidamente (≈ 97 a 98% val acc), com leve *overfitting* após a época 15 (val loss sobe enquanto treino continua caindo; ver notebook, Figura baseline).

3.2 Exploração de hiperparâmetros

Variamos **um hiperparâmetro por vez** (100 épocas, *seeds* 1, 2, 42, 100, 2026). A Tabela 1 resume os resultados.

Tabela 1: Exploração de hiperparâmetros (100 épocas, 5 *seeds*; varia-se um parâmetro por vez).

Parâmetro	Valor	Train acc	Val acc	Val loss
α	0,001	0,628	0,626	0,658
	0,01	0,986	0,978	0,064
	0,1	1,000	0,967	0,009
Batch	8	0,992	0,978	0,024
	32	0,986	0,978	0,064
	64	0,964	0,967	0,141
Arch	[30,16,2]	0,992	0,978	0,025
	[30,32,2]	0,992	0,978	0,024
	[30,64,32,2]	0,995	0,978	0,027

Melhor configuração: $\text{arch}=[30,16,2]$, $\alpha = 0,01$, $\text{batch}=8$ (val acc 0,978; escolhida por parsimônia ante empate). $\alpha = 0,001$ permanece no patamar da classe majoritária ($\approx 0,63$), indicando *underfitting* severo.




Figura 2: Heatmap de val acc ($\alpha \times \text{batch}$).

A Figura 3 evidencia a **fase de latência**: curvas iniciam em $\approx 62,7\%$ (357/569 benignos) enquanto pesos pequenos e ReLUs inativas impedem quebra de simetria. Latência: $\alpha = 0,1 \approx 2$ épocas; $\alpha = 0,01 \approx 18$; $\alpha = 0,001$ não sai do platô; $\text{batch}=8$ mais rápido que 64; rede [30,64,32,2] ≈ 45 épocas.




Figura 3: Curvas de acurácia ao variar α , **batch** e arquitetura (treino pontilhado, validação sólida).

3.3 Treinamento final

Adotamos **early stopping** em duas fases: (1) treinar em treino+validação separados por 200 épocas e identificar a época de menor val loss (época 37, loss 0,108); (2) retrainar em treino∪validação (454 amostras) por exatamente 37 épocas e avaliar o teste uma vez.

4 Resultados

Teste final: acurácia **97,4%** (112/115 corretos), test loss 0,085. A Figura 4 mostra a matriz de confusão.




Figura 4: Matriz de confusão no conjunto de teste final (115 amostras).

Dois falsos positivos (benignos classificados como malignos) e um falso negativo. Sensibilidade para malignos: $42/43 \approx 97,7\%$; especificidade: $70/72 \approx 97,2\%$.

Rede rasa vs. profunda: em val acc as três arquiteturas empatam (0,978), mas a profunda exige muito mais épocas para sair do platô (Figura 3) e apresenta maior train acc (0,995), sugerindo capacidade extra não aproveitada neste dataset tabular pequeno. Optamos pela rede [30,16,2] por parsimônia.

Extras omitidos por brevidade: no notebook também comparamos `MLPClassifier` (sklearn), com mesma test acc (97,4%), e avaliamos inicialização He e momentum (Seção 7), que encurtam a fase de latência; as figuras correspondentes ficam no repositório, mas foram omitidas aqui pelo limite de 6 páginas.

5 Interpretabilidade

Analizamos o `final_model` por gradientes de entrada e ablação. Também implementamos SHAP (Seção 9 do notebook); omitimos essa análise aqui por brevidade e limite de páginas. Os *summary plots* e *waterfalls* SHAP estão em `figures/shap_summary.png`.

5.1 Importância global

Gradientes de entrada (6.1): para cada amostra de teste, calculamos $\partial P(\hat{c})/\partial x_j$ em relação à classe predita e médiamos $|\partial P/\partial x_j|$. A Figura 5 mostra que features `worst_*` ocupam as seis primeiras posições; `worst radius` e `worst texture` lideram ($\approx 0,028$ e $0,027$), seguidas de `worst perimeter`, `worst concave points` e `worst area`. Entre as `mean_*`, destacam-se `mean concave points`, `mean radius` e `mean perimeter`.

Ablação (6.2): zeramos features (individual, por família `mean_*/worst_*/*_error`, ou por atributo-base) e medimos aumento de cross-entropy. Com apenas 115 amostras de teste, queda de acurácia é **discreta** (passos de $1/115 \approx 0,0087$), tornando `accuracy_drop` pouco discriminante. Ranqueamos por `ce_increase` (Figuras 6a a 6c).






Figura 5: Top 10 features por importância global via gradiente de entrada ($|\partial P/\partial x|$ médio no teste).



(a) Ablação por feature individual.

(b) Ablação por família (`mean_*`, `worst_*`, `*_error`).



(c) Ablação por atributo-base (tripla `mean/error/worst`).

Figura 6: Ablação ranqueada por aumento de cross-entropy ao zerar grupos de features.

Na ablação por feature (Figura 6a), `worst texture` (+0,012 CE) e `worst symmetry` (+0,009) lideram. Por família (Figura 6b), remover todo o bloco `worst_*` eleva a CE em $\approx 0,107$, muito acima de `mean_*` (+0,014) e `*_error` (+0,011). Por atributo-base (Figura 6c), `texture` (+0,030) é o mais crítico; `symmetry`, `area` e `concavity` ficam empatados em torno de 0,008 a 0,010.

Discordância entre métodos: gradientes e ablação por feature coincidem parcialmente em `{worst area, worst concave points, worst radius, worst texture}`, mas a ablação por *atributo-base* destaca `texture` enquanto gradientes enfatizam morfologia de raio/perímetro. Essa divergência é esperada: gradientes medem sensibilidade local; ablação mede efeito global de remoção.

6 Discussão crítica

Limitações metodológicas:

1. **Teste pequeno (115 amostras):** métricas de ablação por acurácia são grosseiras; preferimos CE contínua, mas incertezas permanecem elevadas.
2. **Validação estreita (91 amostras):** empates frequentes entre configs (val acc 0,978); escolhemos parsimônia, não superioridade estatística comprovada.
3. **Early stopping + retreino:** embora evitemos *peek* direto no teste durante busca de hiperparâmetros, o número de épocas ótimo foi estimado na validação; retreino em treino+val melhora robustez, mas não elimina variância de *seed*.
4. **Interpretabilidade:** gradientes pontuais e ablação binária (zerar feature) não capturam interações não-lineares; SHAP foi implementado mas omitido do relatório (ver notebook).

O que faríamos diferente: validação cruzada k -fold para seleção de hiperparâmetros; regularização L2 explícita na rede profunda; calibração de probabilidades; técnicas mais suaves (Integrated Gradients); e exportar as curvas de early stopping para o relatório.

Conclusão: a MLP manual atinge desempenho comparável ao `MLPClassifier`, com interpretabilidade consistente no domínio clínico. Medidas `worst_*` e morfologia de concavidade/textura são os preditores mais salientes, mas métodos de explicação devem ser lidos em conjunto, não isoladamente.

Referências

- [1] Pedregosa et al. Scikit-learn: *Breast Cancer Wisconsin (Diagnostic) Dataset*. https://scikit-learn.org/stable/datasets/toy_dataset.html#breast-cancer-dataset